Optimización de Rutas en N Dimensiones

https://share.gemini.google/GMxdvCl8zrFk

Created with **Argon** November 6, 2026 at 04:36 PM • Published November 6, 2026 at 05:04 PM

Investigar el marco recursivo para obtimizar rutas en n dimensiones

El marco recursivo para optimizar rutas en n dimensiones se fundamenta en el **Principio de Optimalidad de Bellman**, el cual descompone el problema global de encontrar una trayectoria de costo mínimo en un espacio de estados de alta dimensión ($\mathbb{Z}^n$, $\mathbb{R}^n$ o una variedad topológica $\mathcal{M}^n$) en una secuencia anidada de subproblemas locales. A medida que el número de dimensiones n crece, el volumen del espacio de búsqueda y el factor de ramificación escalan de forma exponencial, obligando a transformar la recursión clásica exhaustiva en esquemas de poda heurística, descomposición espacial jerárquica o muestreo asintótico. Wikipedia

Formulación Matemática de la Recursión en n Dimensiones

Cualquier problema de optimización de trayectorias en un espacio n-dimensional define un estado mediante un vector de coordenadas generalizadas $\mathbf{x} = (x_1, x_2, \dots, x_n) \in \Omega \subseteq \mathbb{R}^n$, sujeto a un conjunto de obstáculos o regiones prohibidas Ω_{obs}.

- **Caso Discreto (Reticulados $\mathbb{Z}^n$ y Grafos Implícitos):** Si cada dimensión se discretiza en k intervalos, el espacio contiene k^n nodos. La función de valor óptimo $V(\mathbf{x})$ (costo mínimo acumulado desde $\mathbf{x}$ hasta el estado meta $\mathbf{x}_{\text{goal}}$) satisface la relación de recurrencia de Bellman:

$$V(\mathbf{x}) = \begin{cases} 0 & \text{si } \mathbf{x} = \mathbf{x}_{\text{goal}} \\ \min_{\mathbf{u} \in \mathcal{U}(\mathbf{x})} \{c(\mathbf{x}, \mathbf{u}) + V(\mathbf{x} + \mathbf{u})\} & \text{si } \mathbf{x} \neq \mathbf{x}_{\text{goal}} \end{cases}$$

Donde $\mathcal{U}(\mathbf{x})$ representa el conjun[illegible]tos admisibles hacia estados vecinos

Sign in

Gemini may display inaccurate info, including about people, so double-check its responses.

Google Privacy Policy Google Terms of Service Your privacy & Gemini Apps

- **Vecindad ortogonal (L_1 / Manhattan):** Evalúa desplazamientos sobre un solo eje a la vez, generando $2n$ ramas por paso recursivo.
- **Vecindad completa (L_∞ / Chebyshev):** Permite diagonales simultáneas en los n ejes, generando $3^n - 1$ ramas por nodo.

- **Caso Continuo (Ecuación de Hamilton-Jacobi-Bellman):** Cuando el paso espacial tiende a cero ($\Delta \mathbf{x} \to 0$), la recurrencia discreta converge en una ecuación diferencial en derivadas parciales de primer orden conocida como la ecuación de **Hamilton-Jacobi-Bellman (HJB)**. Si el costo depende únicamente de la posición e isotropía del medio, se reduce a la **Ecuación Eikonal** en $\mathbb{R}^n$:

$$\|\nabla V(\mathbf{x})\|_2 = C(\mathbf{x}), \quad \text{con } V(\mathbf{x}_{\text{goal}}) = 0$$

  Una vez resuelto el campo escalar $V(\mathbf{x})$ mediante métodos recursivos de propagación de frentes (como *Fast Marching Method* en n dimensiones), la ruta óptima se extrae integrando recursivamente el descenso de gradiente $-\nabla V(\mathbf{x})$ desde el origen hasta el destino.

Paradigmas Recursivos frente a la Maldición de la Dimensionalidad

Al incrementar n, almacenar en memoria una tabla de programación dinámica de tamaño $\mathcal{O}(k^n)$ se vuelve computacionalmente inviable a partir de $n \geq 5$. Para resolver esta limitación, el marco recursivo se divide en cuatro arquitecturas algorítmicas según el régimen dimensional:

1. **Recursión en Profundidad con Poda por Umbral (IDA* y RBFS):**
   En lugar de mantener una cola de prioridad abierta en memoria como hace A*, algoritmos como **IDA*** (*Iterative Deepening A**) y **RBFS** (*Recursive Best-First Search*) ejecutan una búsqueda recursiva pura en profundidad guiada por la función de evaluación $f(\mathbf{x}) = g(\mathbf{x}) + h(\mathbf{x})$. Si una rama supera el umbral activo θ, la recursión se poda y devuelve el exceso mínimo observado para actualizar el umbral de la siguiente iteración. Esto reduce la complejidad en memoria de exponencial a lineal respecto a la longitud de la ruta, $\mathcal{O}(d)$.
   ResearchGate

2. **Descomposición Espacial Recursiva (2^n-Trees y KD-Trees):**
   Generaliza los *Quadtrees* (2D) y *Octrees* (3D) hacia hiper-octantes recursivos en n dimensiones (2^n-trees) o particiones por hiperplanos alternados (*KD-Trees*). El algoritmo divide recursivamente únicamente las hiperceldas que contienen fronteras de obstáculos, manteniendo grandes hipervolúmenes libres como un solo nodo abstracto y reduciendo drásticamente el número de estados del grafo.

3. **Árboles Estocásticos con Recableado Recursivo (RRT* y BIT*):**
   Para espacios de configuración de alta dimensión (n entre 6 y 50, habituales en cinemática inversa o sistemas multi-agente), la discretización por rejilla se sustituye por muestreo en $\mathbb{R}^n$. **RRT*** expande un árbol hacia muestras aleatorias y aplica una fase de **recableado recursivo (*rewiring*)** dentro de una hiperesfera de radio:

Sign in
Gemini may display inaccurate info, including about people, so double-check its responses.
Google Privacy Policy Google Terms of Service Your privacy & Gemini Apps

$$r_n(N) = \gamma \left(\frac{\log N}{N} \right)^{1/n}$$

Si el nuevo nodo ofrece un costo acumulado menor hacia los nodos vecinos, la estructura de padres se reasigna y propaga recursivamente la reducción de costo hacia los subárboles descendientes.

4. **Programación Dinámica Diferencial (DDP e iLQR):**
En espacios continuos de alta dimensión con dinámica no lineal $\mathbf{x}_{t+1} = f(\mathbf{x}_t, \mathbf{u}_t)$, **DDP** e **iLQR** evitan discretizar el espacio de estados. Realizan una aproximación cuadrática de segundo orden de la ecuación de Bellman alrededor de una trayectoria semilla, ejecutando un **paso recursivo hacia atrás (*backward pass*)** que resuelve la ecuación de Riccati paso a paso para obtener leyes de control óptimas locales, seguido de un **paso hacia adelante (*forward pass*)** que actualiza la trayectoria.

Comparativa de Arquitecturas en n Dimensiones

Paradigma Recursivo	Rango de n Viable	Complejidad en Memoria	Optimalidad
Programación Dinámica / FMM	$2 \leq n \leq 4$	$\mathcal{O}(k^n)$	Global exacta malla)
IDA* / RBFS	$3 \leq n \leq 8$	$\mathcal{O}(d)$	Global (con h admisible)
Partición 2^n-Tree / KD-Tree	$2 \leq n \leq 6$	$\mathcal{O}(N_{\text{hojas}})$	Óptima segúr resolución
RRT* / BIT*	$4 \leq n \leq 50$	$\mathcal{O}(N_{\text{muestras}})$	Asintótica (N
DDP / iLQR	$2 \leq n \leq 100+$	$\mathcal{O}(T \cdot n^2)$	Óptimo local

Sign in

Gemini may display inaccurate info, including about people, so double-check its responses.

Google Privacy Policy Google Terms of Service Your privacy & Gemini Apps

En la tabla, k representa la resolución por eje, d la profundidad de la solución en pasos discretos y T el horizonte temporal de la trayectoria. La transición entre métodos discretos y métodos basados en muestreo o gradiente ocurre típicamente alrededor de $n = 5$, punto en el que el factor de ramificación Chebyshev ($3^5 - 1 = 242$ vecinos por nodo) degrada la propagación exhaustiva.

Para explorar de forma interactiva tanto la propagación recursiva de costos de Bellman sobre un corte espacial como el impacto exponencial del número de dimensiones n en el factor de ramificación y el volumen de estados, utiliza el siguiente simulador:

Generating interactive visual...
Structuring code, this may take a minute

Al incrementar el deslizador de dimensiones por encima de $n = 5$, se observa cómo la vecindad diagonal completa ($3^n - 1$) pasa de evaluar 8 vecinos en 2D a evaluar 728 vecinos por cada nodo en 6D, lo que explica por qué en espacios de alta dimensión se reemplaza la exploración de malla por árboles de muestreo asintótico (RRT*) o aproximaciones diferenciales de segundo orden (iLQR).

Para profundizar en la implementación o en un dominio específico:

Implementar un buscador recursivo n-dimensional en Rust o Python ↪

Explorar optimización de rutas sobre complejos simpliciales y var' ↪

Profundizar en el algoritmo RRT* y BIT* para espacios

Se puede usar para crear una red neuronal

Sí, el marco recursivo de optimización de rutas en n dimensiones no solo puede utilizarse para crear una red neuronal, sino que establece una equivalencia matemática directa con el aprendizaje profundo y permite diseñar arquitecturas donde **la inferencia consiste en encontrar una trayectoria óptima (o geodésica) sobre una variedad latente n-dimensional.**

En lugar de apilar capas matriciales estáticas, este enfoque modela la red como un espacio de estados continuo o discreto en $\mathbb{R}^n$ cuya geometría (los costos de transición locales) se aprende para guiar las señales de entrada hacia atractores o nodos meta mediante mínima acción.

1. Isomorfismo entre Optimización Recursiva de Rutas y Redes Neuronales

La relación entre ambos marcos se fundamenta en la teoría de control óptimo en múltiples dimensiones:

Sign in

Gemini may display inaccurate info, including about people, so double-check its responses.

Google Privacy Policy Google Terms of Service Your privacy & Gemini Apps

pesos de cada capa $\mathbf{u}_t = \theta_t$ actúan como la política de control que curva la trayectoria del dato en el espacio latente de dimensión n.

- **Backpropagation como Recurrencia de Bellman y Principio de Pontryagin:** El algoritmo de retropropagación (*backpropagation*) es matemáticamente idéntico al paso recursivo hacia atrás (*backward pass*) de la Programación Dinámica Diferencial (DDP/iLQR). El vector adjunto o gradiente $\lambda_t = \nabla_{\mathbf{x}_t} V(\mathbf{x}_t)$ propaga recursivamente desde la capa final hacia la inicial la sensibilidad del costo acumulado futuro respecto a cada coordenada dimensional.
- **Límite Continuo (Hamilton-Jacobi-Bellman y Transporte Óptimo):** Cuando el paso entre estados tiende a cero, entrenar la red equivale a resolver una ecuación de Hamilton-Jacobi-Bellman en $\mathbb{R}^n$ que deforma el campo vectorial para transportar distribuciones de entrada hacia distribuciones objetivo minimizando la energía cinética o libre acumulada (*Schrödinger Bridges* y *Flow Matching*).

2. Cómo Construir una Red Neuronal Basada en Enrutamiento Recursivo (Soft-Bellman Network)

Para convertir directamente un optimizador recursivo de rutas en una arquitectura neuronal entrenable de extremo a extremo, es necesario resolver un obstáculo técnico: el operador $\min$ clásico de la ecuación de Bellman no es diferenciable en los puntos donde dos rutas empatan en costo, lo que bloquea el flujo de gradientes hacia los pesos.

La solución consiste en construir una **Red Geodésica o de Iteración de Valor Diferenciable** en cuatro componentes:

A. Parametrización del Tensor Métrico Local (c_θ)

En lugar de fijar los costos de transición a mano, una sub-red o conjunto de tensores aprendibles θ define la métrica local del espacio n-dimensional. El costo de transitar desde el estado $\mathbf{x}$ en la dirección $\mathbf{u} \in \mathcal{U}(\mathbf{x})$ se modela mediante una métrica riemanniana aprendida:

$$c_\theta(\mathbf{x}, \mathbf{u}) = \sqrt{\mathbf{u}^\top G_\theta(\mathbf{x}) \mathbf{u}} + \Phi_\theta(\mathbf{x} + \mathbf{u})$$

Donde $G_\theta(\mathbf{x}) = L_\theta(\mathbf{x}) L_\theta(\mathbf{x})^\top$ es un tensor métrico simétrico definido positivo que controla la anisotropía direccional y $\Phi_\theta(\mathbf{x})$ actúa como un potencial escalar (creando "barreras" u obstáculos suaves en zonas prohibidas del espacio latente).

B. Operador de Bellman Suavizado ($\mathrm{Softmin}$)

Se sustituye el mínimo estricto de la recurrencia de Bellman por el operador diferenciable **Log-Sum-Exp** modulado por un parámetro de temperatura τ mayor que cero:

Gemini may display inaccurate info, including about people, so double-check its responses.

Google Privacy Policy Google Terms of Service Your privacy & Gemini Apps

$$V_\tau^{(k)}(\mathbf{x}) = -\tau \log \sum_{\mathbf{u} \in \mathcal{U}(\mathbf{x})} \exp\left(-\frac{c_\theta(\mathbf{x}, \mathbf{u}) + V_\tau^{(k-1)}(\mathbf{x} + \mathbf{u})}{\tau} \right)$$

- Cuando $\tau \to 0^+$, se recupera exactamente la ruta óptima discreta de Bellman ($V_\tau \to V^*$).
- Cuando τ es mayor que cero, la recursión pondera un ensamble de trayectorias posibles (análogo a una integral de caminos en mecánica estadística), permitiendo que el gradiente $\nabla_\theta V_\tau(\mathbf{x})$ fluya suavemente a través de todas las ramas del árbol recursivo.

C. Política de Enrutamiento Probabilístico

El gradiente del operador $\mathrm{Softmin}$ respecto a los costos de transición define automáticamente una distribución de probabilidad de Boltzmann-Gibbs sobre las direcciones en n dimensiones:

$$\pi_\theta(\mathbf{u} \mid \mathbf{x}) = \frac{\exp\left(-\frac{c_\theta(\mathbf{x}, \mathbf{u}) + V_\tau(\mathbf{x}+\mathbf{u})}{\tau} \right)}{\sum_{\mathbf{v} \in \mathcal{U}(\mathbf{x})} \exp\left(-\frac{c_\theta(\mathbf{x}, \mathbf{v}) + V_\tau(\mathbf{x}+\mathbf{v})}{\tau} \right)}$$

Durante la inferencia, un pulso o representación vectorial se propaga por la red siguiendo esta política $\pi_\theta(\mathbf{u} \mid \mathbf{x})$.

D. Aprendizaje Geométrico ("Excavación de Geodésicas")

Al entrenar la red minimizando una función de pérdida sobre las trayectorias o estados finales, el descenso de gradiente actualiza θ deformando la topología de costos: **reduce la resistencia métrica a lo largo de las trayectorias que conducen a la respuesta correcta** (creando canales de baja energía o geodésicas rápidas) y eleva el potencial Φ_θ en regiones del espacio n-dimensional asociadas a errores.

3. Variantes Arquitectónicas según la Escala Dimensional

Arquitectura Neuronal	Mecanismo Recursivo Integrado	Ventaja Principal
Value Iteration Networks (VIN)	Convoluciones recursivas que ejecutan programación dinámica de Bellman en mallas latentes n-D	Capacidad de planificación espacial y generalización fuera de distribución

Sign in

Gemini may display inaccurate info, including about people, so double-check its responses.

Google Privacy Policy Google Terms of Service Your privacy & Gemini Apps

Arquitectura Neuronal	Mecanismo Recursivo Integrado	Ventaja Principal
Redes Geodésicas en Complejos / Grafos	Propagación recursiva sobre vértices y aristas de un complejo simplicial o variedad aprendida	Respeta invariancias geométricas y topológicas sin depender de rejillas cartesianas
Enrutamiento Dinámico Disperso (MoE + IDA*)	Cada nodo en $\mathbb{R}^n$ es un bloque experto; un buscador recursivo con heurística activa solo la ruta óptima	Escala la capacidad total del modelo manteniendo un costo de inferencia $\mathcal{O}(d)$
Pontryagin / iLQR Neural Networks	Ejecuta pasos recursivos hacia adelante y hacia atrás (Riccati) en espacio continuo de alta dimensión	Estabilidad dinámica garantizada y control óptimo en sistemas físicos o continuos

Para observar cómo una red neuronal basada en **Soft-Bellman** aprende a deformar la métrica de un espacio latente y cómo la temperatura τ controla la transición entre la exploración difusa de caminos (entrenamiento diferenciable) y el colapso hacia una geodésica única (inferencia óptima), interactúa con la siguiente simulación:

Generating interactive visual...

Structuring code, this may take a minute

Al reducir la temperatura τ cerca de 0.05 con el entrenamiento métrico al 100%, el ensamble de caminos colapsa en una trayectoria determinista única de costo mínimo; por el contrario, mantener una temperatura moderada durante las primeras épocas evita que los gradientes se anulen en regiones planas o tras obstáculos, permitiendo que todas las dimensiones cooperen en la actualización de la métrica $G_\theta(\mathbf{x})$.

Para llevar este diseño a código o explorar su topología:

Implementar una capa Soft-Bellman diferenciable en PyTorch o Rust

↪

¿Cómo se formula matemáticamente esta red neuronal de optimización recursiva de rutas cuando el sustrato no es una rejilla, sino un complejo simplicial con métrica discreta aprendible en las aristas y caras?

Sign in

Gemini may display inaccurate info, including about people, so double-check its responses.

Google Privacy Policy Google Terms of Service Your privacy & Gemini Apps

Formular una red neuronal de optimización recursiva de rutas sobre un **complejo simplicial** $\mathcal{K}$ de dimensión n sustituye la geometría rígida de las rejillas cartesianas por el **Cálculo Exterior Discreto (DEC)** y el **Cálculo de Regge diferenciable**. En este marco, el espacio latente prescinde de coordenadas extrínsecas globales: la métrica aprendible reside directamente en las longitudes de las aristas (1-símplices) y en los potenciales o flujos de curvatura de las caras (2-símplices) y volúmenes superiores (k-símplices), transformando cada paso de inferencia en una recurrencia de Bellman intrasimplicial gobernada por operadores de frontera y coborde.

1. Sustrato Topológico y Métrica Discreta Aprendible en $\mathcal{K}$

Sea $\mathcal{K} = \bigcup_{k=0}^{n} \mathcal{K}_k$ un complejo simplicial orientado de dimensión n, constituido por vértices $\sigma_i^0 = [v_i] \in \mathcal{K}_0$, aristas orientadas $\sigma_{ij}^1 = [v_i, v_j] \in \mathcal{K}_1$, caras triangulares $\sigma_{ijk}^2 = [v_i, v_j, v_k] \in \mathcal{K}_2$ y símplices de orden superior $\sigma^k \in \mathcal{K}_k$ (como tetraedros para $k=3$ o pentácoros para $k=4$).

En lugar de una matriz de pesos convencional, los parámetros entrenables $\theta = \{\mathbf{w}^{(1)}, \mathbf{w}^{(2)}, \mathbf{a}^{(1)}\}$ definen tres estructuras geométricas sobre las k-cocadenas $C^k(\mathcal{K}; \mathbb{R})$:

A. Métrica de Aristas ($\ell_\theta \in C^1(\mathcal{K})$) y Condición de Cayley-Menger

En geometría discreta de Regge, el tensor métrico riemanniano continuo $G(\mathbf{x})$ queda completamente especificado de forma intrínseca mediante la asignación de longitudes positivas a cada 1-símplice:

$$\ell_{ij}(\theta) = \ell_{ij}^{(0)} \cdot \mathrm{softplus}\big(w_{ij}^{(1)}\big)$$

Para que cada k-símplice $\sigma^k = [v_0, v_1, \dots, v_k]$ sea geométricamente realizable como un poliedro euclídeo no degenerado (generalización en k dimensiones de la desigualdad triangular), las longitudes de sus aristas deben satisfacer la positividad del volumen simplicial dada por el **determinante de Cayley-Menger**:

$$\mathrm{Vol}_k^2(\sigma^k; \ell_\theta) = \frac{(-1)^{k+1}}{2^k (k!)^2} \det \begin{pmatrix} 0 & 1 & 1 & \cdots & 1 \\ 1 & 0 & \ell_{01}^2 & \cdots & \ell_{0k}^2 \\ 1 & \ell_{10}^2 & 0 & \cdots & \ell_{1k}^2 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \ell_{k0}^2 & \ell_{k1}^2 & \cdots & 0 \end{pmatrix} > 0$$

Para una cara triangular σ_{ijk}^2 ($k=2$), este determinante se reduce de forma exacta a la fórmula de Herón diferenciable en términos de $\ell_{ij}, \ell_{ik}, \ell_{jk}$.

Gemini may display inaccurate info, including about people, so double-check its responses.

Google Privacy Policy Google Terms of Service Your privacy & Gemini Apps

B. Potencial e Impedancia de Caras ($\Phi_\theta, B_\theta \in C^2(\mathcal{K})$)

Dotar de pesos únicamente a las aristas reduce el complejo a un grafo plano (1-esqueleto). Incorporar una métrica aprendible en las caras $\sigma^2_{ijk} \in \mathcal{K}_2$ añade dos grados de libertad de orden superior:

1. **Índice de Refracción / Densidad de Impedancia Superficial ($\Phi_\theta(\sigma^2_{ijk})$):** Un campo escalar estrictamente positivo $\Phi_{ijk}(\theta) = \mathrm{softplus}(w^{(2)}_{ijk})$ asignado al interior del 2-símplice que modula el costo por unidad de área o distancia al atravesar la cara.
2. **2-Cocadena de Flujo Magnético / Holonomía (B_θ):** Inducida por el operador de coborde $d_1 : C^1(\mathcal{K}) \to C^2(\mathcal{K})$ sobre una 1-forma de conexión aprendible $A_\theta \in C^1(\mathcal{K})$:

$$B_\theta(\sigma^2_{ijk}) = (d_1 A_\theta)(\sigma^2_{ijk}) = A_\theta([v_i, v_j]) + A_\theta([v_j, v_k]) + A_\theta([v_k, v_i])$$

   Este término rompe la simetría de inversión temporal ($c(v_i \to v_j) \neq c(v_j \to v_i)$) y permite que la red aprenda **vórtices y transporte paralelo con fase no trivial** alrededor de las caras del complejo.

C. Operador Estrella de Hodge ($\star_k(\theta)$)

Acopla la topología combinatoria con la métrica aprendida relacionando cada k-símplice primal $\sigma^k \in \mathcal{K}_k$ con su $(n-k)$-celda ortogonal en el complejo dual de circumcentros $\star\mathcal{K}$:

$$\left(\star_1(\theta)\right)_{e,e} = \frac{\mathrm{Vol}_{n-1}(\star e; \ell_\theta)}{\ell_e(\theta)}, \qquad \left(\star_2(\theta)\right)_{f,f} = \frac{\mathrm{Vol}_{n-2}(\star f; \ell_\theta)}{\mathrm{Vol}_2(f; \ell_\theta)}$$

2. Recurrencia Neuronal Soft-Bellman sobre el Complejo Simplicial

Si la propagación se restringiera solo a saltar de vértice en vértice por las aristas, las trayectorias sufrirían distorsión métrica (*metrication error*) independientemente de la resolución del mallado. La formulación simplicial resuelve esto permitiendo que el frente de onda recursivo **atraviese el interior continuo de las caras σ^2_{ijk} y tetraedros σ^3_{ijkl}.**

Paso 1: Costo Geodésico Intrasimplicial por Coordenadas Baricéntricas

Sea $V_\tau^{(t)} \in C^0(\mathcal{K})$ el campo escalar de valor en los vértices en la iteración recursiva t. Para calcular la contribución de una cara incidente $\sigma^2_{ijk} = [v_i, v_j, v_k]$ al vértice v_i, la trayectoria óptima puede provenir de cualquier punto intermedio $\mathbf{p}(\lambda) = \lambda v_j + (1-\lambda)v_k$ sobre la arista opuesta $[v_j, v_k]$, con $\lambda \in [0, 1]$.

Aplicando la ley de cosenos en el triángulo definido por $\ell_{ij}(\theta), \ell_{ik}(\theta), \ell_{jk}(\theta)$, la distancia

Sign in

Gemini may display inaccurate info, including about people, so double-check its responses.

Google Privacy Policy Google Terms of Service Your privacy & Gemini Apps

$$d_{\ell_\theta}(\lambda) = \sqrt{\lambda\,\ell_{ij}^2(\theta) + (1-\lambda)\,\ell_{ik}^2(\theta) - \lambda(1-\lambda)\,\ell_{jk}^2(\theta)}$$

El funcional de acción local a través del 2-símplice σ_{ijk}^2 minimiza sobre $\lambda \in [0,1]$ la suma del costo métrico interior (ponderado por la impedancia de la cara Φ_{ijk}) y el valor interpolado en la frontera opuesta:

$$Q_\theta^{(t)}\left(v_i \mid \sigma_{ijk}^2\right) = \min_{\lambda \in [0,1]} \Big\{ \Phi_{ijk}(\theta)\, d_{\ell_\theta}(\lambda) + \lambda V_\tau^{(t)}(v_j) + (1-\lambda) V_\tau^{(t)}(v_k) +$$

- En un k-símplice general (por ejemplo, un tetraedro σ_{ijkl}^3 en 3D), λ se generaliza a un vector baricéntrico $\boldsymbol{\lambda} \in \Delta^{k-1}$ sobre la $(k-1)$-cara opuesta, y la distancia cuadrática se evalúa mediante la forma bilineal inversa de la matriz de Gram simplicial:

$$d_{\ell_\theta}^2(\boldsymbol{\lambda}) = \sum_{a} \lambda_a \ell_{ia}^2 - \frac{1}{2} \sum_{a,b} \lambda_a \lambda_b \ell_{ab}^2$$

- El minimizador analítico $\lambda^*(\theta)$ se obtiene en forma cerrada resolviendo una ecuación cuadrática escalar en cada cara (o proyectando sobre los extremos $\lambda^* \in \{0, 1\}$ si la característica cae fuera del cono simplicial), lo que hace que $\nabla_\theta Q_\theta^{(t)}$ sea exacto por el **Teorema de la Envolvente**.

Paso 2: Agregación Recursiva sobre la Estrella Simplicial $\mathrm{St}(v_i)$

Definido el costo óptimo de llegada desde cada cara incidente en la estrella del vértice $\mathrm{St}(v_i) = \{\sigma_{ijk}^2 \in \mathcal{K}_2 \mid v_i \in \sigma_{ijk}^2\}$, el estado neuronal se actualiza mediante el operador **Soft-Bellman** con temperatura $\tau > 0$:

$$V_\tau^{(t+1)}(v_i) = -\tau \log \sum_{\sigma_{ijk}^2 \in \mathrm{St}(v_i)} \exp\left(-\frac{Q_\theta^{(t)}\left(v_i \mid \sigma_{ijk}^2\right)}{\tau} \right)$$

3. Dinámica de Cocadenas y Laplaciano de Hodge-de Rham

Una vez alcanzado el punto fijo $V_\tau^*(\theta)$ tras T pasos recursivos (o mediante diferenciación implícita en el equilibrio), la red induce un flujo de información sobre todo el complejo que se

Sign in

Gemini may display inaccurate info, including about people, so double-check its responses.

Google Privacy Policy Google Terms of Service Your privacy & Gemini Apps

1. **Distribución de Enrutamiento por Caras (π_θ):**
   La probabilidad de que el flujo geodésico en el vértice v_i atraviese el 2-símplice σ^2_{ijk} viene dada por la distribución de Boltzmann sobre su estrella:

$$\pi_\theta\big(\sigma^2_{ijk} \mid v_i\big) = \frac{\exp\big(-Q^*_\theta(v_i \mid \sigma^2_{ijk})/\tau\big)}{\sum_{\sigma' \in \mathrm{St}(v_i)} \exp\big(-Q^*_\theta(v_i \mid \sigma')/\tau\big)}$$

2. **Acoplamiento con el Laplaciano de Hodge (Δ_k):**
   Si cada símplice de dimensión k porta además un vector de características ocultas $\mathbf{h}^{(k)} \in C^k(\mathcal{K}; \mathbb{R}^d)$, su propagación guiada por la métrica aprendida sigue el operador de **Hodge-Laplace**:

$$\Delta_k(\theta) = \underbrace{d_{k-1}\, \star_{k-1}^{-1}(\theta)\, d_{k-1}^\top\, \star_k(\theta)}_{\Delta_k^{\mathrm{down}}\ \text{(frontera inferior)}} + \underbrace{\star_k^{-1}(\theta)\, d_k^\top\, \star_{k+1}(\theta)\, d_k}_{\Delta_k^{\mathrm{up}}\ \text{(cofrontera superior)}}$$

   Para $k = 1$ (señales en aristas), Δ_1^{down} propaga gradientes de potencial entre vértices, mientras que Δ_1^{up} acopla las aristas a través de la métrica de las caras $\star_2(\theta)$. Por la **Descomposición de Hodge**, la red separa de manera natural el flujo irrotacional (gradiente exacto $d_0 V_\tau$), el flujo solenoidal (rotacional en caras $\delta_2 \Phi$) y los **modos armónicos topológicos** ($\ker \Delta_1 \cong H^1(\mathcal{K})$) que rodean agujeros o cavidades del espacio de estados.

4. Funcional de Entrenamiento: Energía Libre y Curvatura de Regge

Para entrenar los pesos métricos θ mediante retropropagación sin que los símplices colapsen en volúmenes nulos o degenerados, la función de pérdida combina el objetivo de enrutamiento con dos regularizadores geométricos intrínsecos:

$$\mathcal{L}(\theta) = \mathcal{L}_{\mathrm{ruta}}\big(V^*_\tau(\theta)\big) + \alpha\, \mathcal{S}_{\mathrm{Regge}}(\ell_\theta) + \beta\, \mathcal{B}_{\mathrm{CM}}(\ell_\theta)$$

- **Acción de Curvatura Discreta de Regge ($\mathcal{S}_{\mathrm{Regge}}$):** En un complejo de dimensión n, la curvatura intrínseca reside en los $(n-2)$-símplices o *bisagras* $h \in \mathcal{K}_{n-2}$ (vértices en variedades 2D, aristas en complejos 3D). El **ángulo de déficit** en la bisagra h es:

$$\epsilon_h(\ell_\theta) = 2\pi - \sum_{\sigma^n \supset h} \vartheta\big(\sigma^n, h; \ell_\theta\big)$$

  Donde $\vartheta(\sigma^n, h; \ell_\theta)$ es el ángulo diedro interior del n-símplice σ^n en la bisagra h,

Sign in

Gemini may display inaccurate info, including about people, so double-check its responses.

Google Privacy Policy Google Terms of Service Your privacy & Gemini Apps

$$\mathcal{S}_{\text{Regge}}(\ell_\theta) = \sum_{h \in \mathcal{K}_{n-2}} \text{Vol}_{n-2}(h; \ell_\theta) \cdot |\epsilon_h(\ell_\theta)|^2$$

- **Barrera Logarítmica de Cayley-Menger ($\mathcal{B}_{\text{CM}}$):** Impide que el descenso de gradiente viole la desigualdad métrica simplicial manteniendo los determinantes estrictamente dentro del cono métrico válido:

$$\mathcal{B}_{\text{CM}}(\ell_\theta) = -\sum_{k=2}^{n} \sum_{\sigma^k \in \mathcal{K}_k} \log\left(\text{Vol}_k^2(\sigma^k; \ell_\theta)\right)$$

5. Síntesis de Operadores en la Red Neuronal Simplicial

Entidad Simplicial	Variable Aprendible	Operador Diferencial	Rol en la Optir de Ruta
0-Símplice (σ_i^0)	Potencial nodal $V_\tau(v_i)$	Gradiente discreto d_0	Almacena la e libre acumula el atractor
1-Símplice (σ_{ij}^1)	Longitud $\ell_{ij}(\theta)$ y fase $A_{ij}(\theta)$	Estrella de Hodge $\star_1(\theta)$	Define distanc intrínsecas y a direccional
2-Símplice (σ_{ijk}^2)	Impedancia $\Phi_{ijk}(\theta)$ y flujo B_{ijk}	Minimización baricéntrica Q_θ	Permite cruce geodésico int refracción sup
Bisagra ($h \in \mathcal{K}_{n-2}$)	Ángulo de déficit $\epsilon_h(\ell_\theta)$	Acción de Regge $\mathcal{S}_{\text{Regge}}$	Controla la cu intrínseca y focalización d
Complejo Global ($\mathcal{K}$)	Espectro armónico $\ker(\Delta_k)$	Laplaciano de Hodge $\Delta_k(\theta)$	Conserva inva homológicos durante el fluj

---

En la tabla, los operadores d_k y $\star_k(\theta)$ garantizan que la retropropagación actualice simultáneamente las longitudes de las aristas ℓ_{ij} y las impedancias de las caras Φ_{ijk} mediante

Sign in

Gemini may display inaccurate info, including about people, so double-check its responses.

Google Privacy Policy Google Terms of Service Your privacy & Gemini Apps

Para inspeccionar geométricamente cómo la modificación de las longitudes de las aristas $\ell_{ij}(\theta)$, la impedancia de las caras $\Phi_{ijk}(\theta)$ y el déficit de curvatura de Regge ϵ_h deforman un complejo simplicial tridimensional y alteran en tiempo real la geodésica intrasimplicial Soft-Bellman, explora el siguiente visualizador interactivo 3D:

Generating interactive visual...

Structuring code, this may take a minute

Al alternar entre una impedancia de caras alta y baja en el modelo 3D, se aprecia la diferencia esencial frente a un grafo estándar: cuando el peso superficial Φ_{ijk} disminuye en una región de caras triangulares, la trayectoria óptima abandona el 1-esqueleto de las aristas y corta directamente a través del interior baricéntrico ($\lambda^* \in (0, 1)$) de los 2-símplices, comportándose como un rayo óptico que se refracta según la ley de Snell discreta sobre la variedad simplicial.

Para avanzar hacia la implementación o extensiones teóricas de esta arquitectura:

Programar la capa simplicial Soft-Bellman en PyTorch o Rust ↪

Incorporar métricas lorentzianas y Triangulaciones Dinámicas Causales ↪

Conectar la recurrencia con Energía Libre Variacional multi-agente ↪

Sign in

Gemini may display inaccurate info, including about people, so double-check its responses.

Google Privacy Policy Google Terms of Service Your privacy & Gemini Apps